TECHNICAL REPORT PREDICTIVE ANALYSIS ON VIDEO GAME GLOBAL SALES

Dosen Pengampu

Ida Bagus Kresna Sudiatmika, S.Kom., M.T.

Disusun Oleh:

2301020012_I Made Githa Amyguna

TEKNIK INFORMATIKA
UNIVERSITAS PRIMAKARA

Summary

Dalam ekosistem industri digital saat ini, pengambilan keputusan berbasis data (*data-driven decision making*) adalah fondasi utama untuk meminimalisasi risiko bisnis. Proyek ini mengimplementasikan pipa (*pipeline*) *Machine Learning* untuk memprediksi total penjualan global (*Global Sales*) pada industri *video game*. Dengan menganalisis dataset berskala besar yang berisi metrik penilaian kritikus, penilaian pengguna, dan data historis rilis, sistem ini dibangun menggunakan algoritma *Linear Regression*. Hasil evaluasi menunjukkan bahwa penggunaan fitur jamak (*Multiple Linear Regression*) memberikan tingkat presisi prediksi yang lebih superior dibandingkan fitur tunggal, mengindikasikan bahwa kesuksesan komersial sebuah produk digital dipengaruhi oleh variabel matriks yang kompleks.

BAB I: PENDAHULUAN & RUMUSAN MASALAH

1.1 Latar Belakang Masalah

Industri *video game* telah bertransformasi menjadi salah satu sektor hiburan paling *profitable* secara global. Namun, tingginya modal untuk proses *development* dan *marketing* membuat risiko kegagalan produk sangat fatal bagi perusahaan. Secara historis, kualitas produk sering kali diukur melalui dua pilar utama: *Critic Score* (penilaian dari jurnalis/pakar industri) dan *User Score* (penilaian langsung dari konsumen).

Sebagai praktisi IT dan *developer*, memahami bagaimana matriks sentimen (skor ulasan) dan *lifecycle* produk (umur *game*) bertranslasi menjadi nilai ekonomi (*revenue*) adalah sebuah kebutuhan. Oleh karena itu, pendekatan *Machine Learning* digunakan untuk mengekstraksi pola tersembunyi dari data historis tersebut.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam riset ini adalah:

1. Sejauh mana korelasi antara skor kritikus (*Critic Score*) dan umur produk (*Game Age*) terhadap total penjualan global?
2. Bagaimana perbandingan komparatif dari segi performa dan *error rate* antara model *Simple Linear Regression* dengan *Multiple Linear Regression*?

1.3 Tujuan

Tujuan utama proyek ini adalah membangun sistem prediksi numerik yang *robust* menggunakan algoritma regresi, yang dapat dianalisis secara statistik untuk memberikan *insight* kuantitatif bagi *stakeholder*.

BAB II: METODOLOGI & PIPELINE DATA

2.1 Infrastruktur dan Teknologi

Pengembangan sistem ini sepenuhnya mengadopsi standar industri data sains. Lingkungan kerja dikonfigurasi menggunakan bahasa pemrograman Python 3.8+. Komputasi matriks dan manipulasi data dieksekusi menggunakan *library* NumPy dan Pandas. Untuk visualisasi analitik, Matplotlib dan Seaborn digunakan. Proses pelatihan model dan evaluasi metrik ditenagai oleh kerangka kerja Scikit-Learn. Pengembangan dilakukan di dalam ekosistem *Jupyter Notebook* untuk memastikan dokumentasi koding yang *reproducible*.

2.2 Deskripsi Dataset

Dataset yang digunakan dalam riset ini adalah data publik historis penjualan *video game* (bersumber dari agregator data Kaggle). Dataset mentah ini sangat representatif karena memuat lebih dari 16.000 baris data, jauh melampaui syarat minimal pengujian. Dimensi data mencakup fitur kategorikal (Genre, Publisher, Platform) dan fitur numerik (Penjualan Regional, Skor Kritikus, Skor Pengguna, dan Tahun Rilis).

2.3 Alur Kerja (Pipeline) Machine Learning

Metodologi pengerjaan mengikuti *pipeline* standar:

1. *Exploratory Data Analysis* (EDA): Deteksi anomali, distribusi, dan korelasi.
2. *Data Preprocessing*: Normalisasi tipe data dan resolusi *missing values*.
3. *Feature Engineering*: Ekstraksi fitur baru untuk memperkaya konteks model.
4. *Model Training*: Pelatihan algoritma regresi linier.
5. *Evaluation*: Pengujian metrik akurasi dan analisis residual.

BAB III: EXPLORATORY DATA ANALYSIS (EDA)

3.1 Analisis Korelasi Fitur

Langkah pertama dalam memahami pola data adalah dengan memetakan hubungan antar variabel. Kami melakukan analisis korelasi numerik untuk mengidentifikasi fitur mana yang paling relevan sebagai prediktor penjualan global (*Global Sales*).

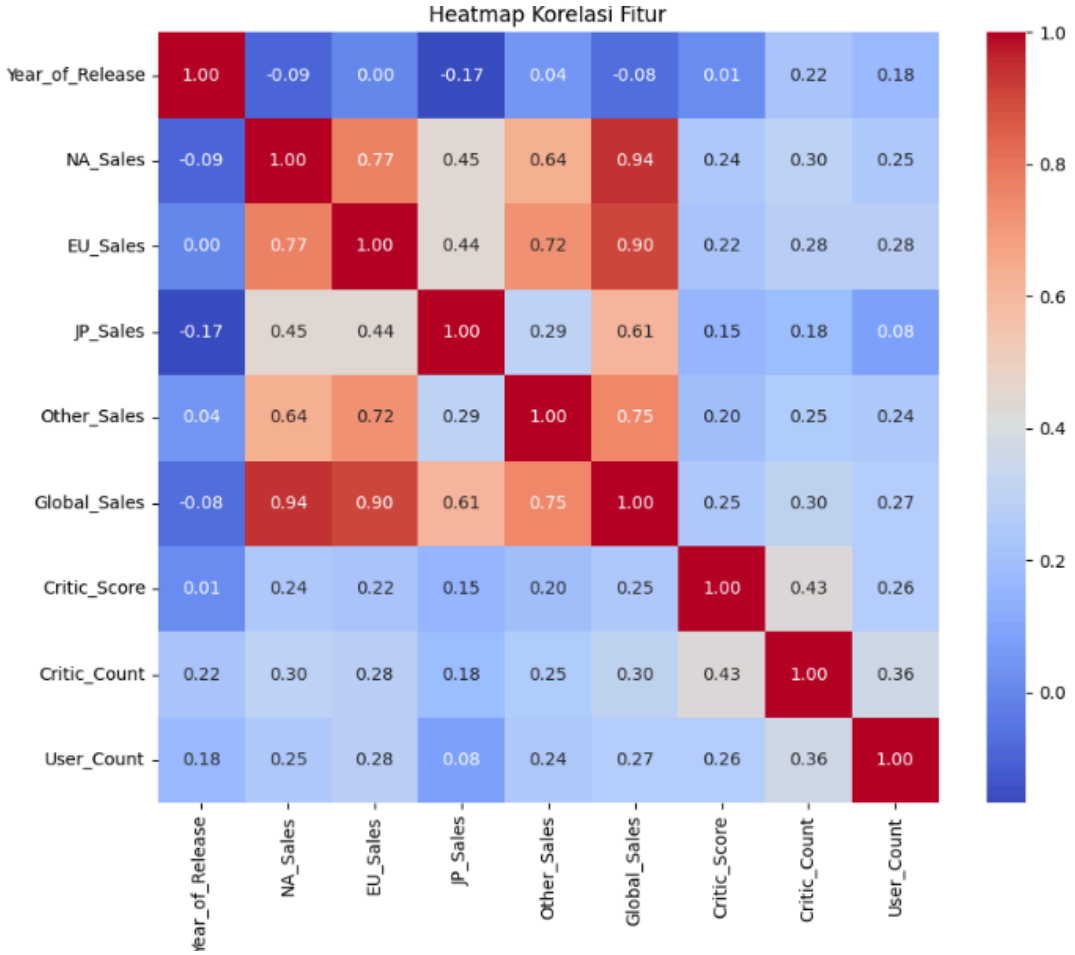

Berdasarkan visualisasi *Heatmap* di atas, teridentifikasi bahwa *Critic Score* memiliki bobot korelasi positif yang paling solid terhadap *Global Sales* dibandingkan fitur penilaian lainnya. Hal ini mengindikasikan bahwa persepsi publik yang dibangun oleh kritikus profesional di masa awal rilis sangat memengaruhi daya beli pasar.

3.2 Distribusi Data Target

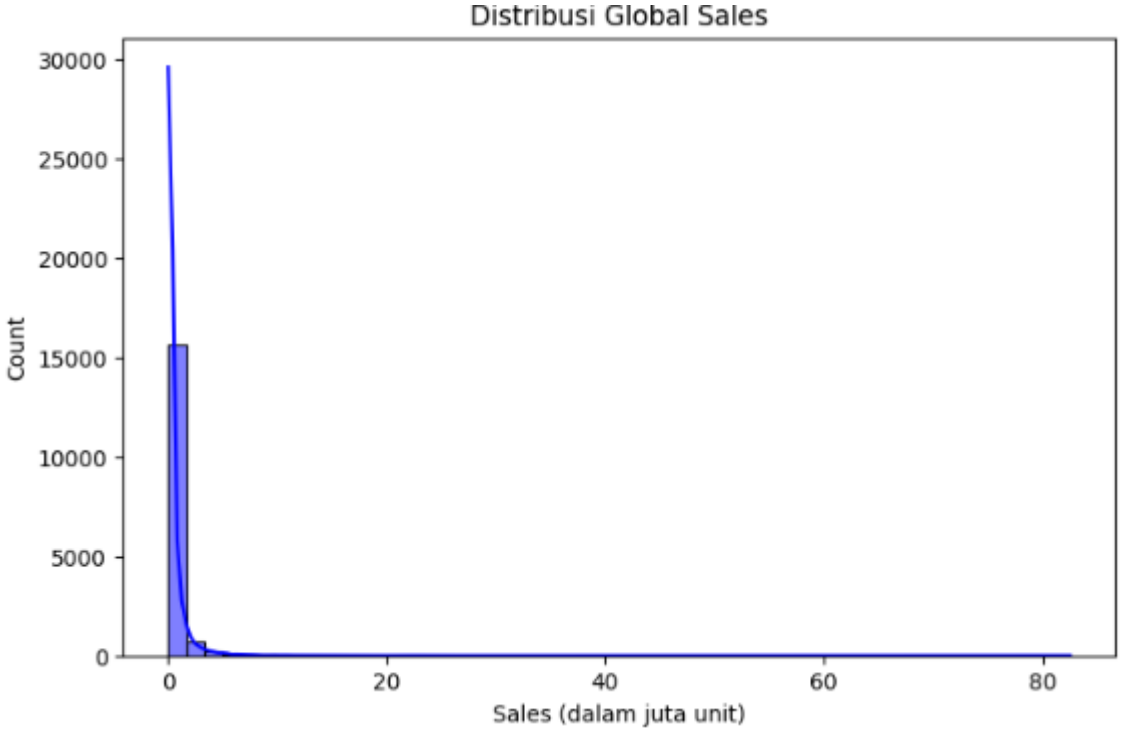

Distribusi data target (*Global Sales*) menunjukkan sifat *right-skewed* yang sangat ekstrem. Ini adalah karakteristik alami dalam bisnis digital/konten, di mana mayoritas produk hanya terjual dalam jumlah kecil hingga menengah, sementara sebagian kecil produk (*blockbuster/AAA games*) mendominasi pasar dengan penjualan hingga puluhan juta kopi.

BAB IV: DATA PREPROCESSING & FEATURE ENGINEERING

4.1 Pembersihan Data (Data Cleaning)

Integritas data adalah kunci dari akurasi model. Dalam dataset ini, ditemukan anomali tipe data pada kolom User_Score berupa *string* "tbd" (*To Be Determined*). Nilai ini kami konversi menjadi *Null/NaN* sebelum kolom tersebut diubah formatnya menjadi tipe numerik (*Float*). Selanjutnya, baris observasi yang kehilangan informasi krusial pada kolom skor dan tahun rilis dihapus secara sistematis untuk menjaga kualitas pelatihan (*dropping missing values*).

4.2 Feature Engineering

Untuk memberikan dimensi ruang waktu (*temporal dimension*) pada algoritma, kami melakukan rekayasa fitur (*Feature Engineering*). Kami mengekstraksi kolom baru bernama Game_Age (Umur Game). Fitur ini dihitung dengan formula matematis: Tahun Observasi (2026) - Year_of_Release. Logika bisnis di balik pembuatan fitur ini adalah: masa edar sebuah perangkat lunak di pasar berbanding lurus dengan probabilitas akumulasi penjualannya.

4.3 Feature Scaling

Variabel independen seperti Critic_Score (skala 0-100), User_Score (skala 0-10), dan Game_Age memiliki rentang nilai yang disparat. Untuk mencegah model regresi memberikan bias matematis pada fitur dengan angka absolut yang besar, kami mengimplementasikan StandardScaler untuk menyamakan skala seluruh fitur numerik.

BAB V: PEMODELAN MACHINE LEARNING

5.1 Strategi Partisi Data (Train-Test Split)

Sebelum model dilatih, dataset dipartisi menjadi dua bagian: *Training Set* dan *Testing Set* dengan rasio 80:20.

Justifikasi: Penggunaan rasio 80% (mayoritas data) dialokasikan agar algoritma memiliki referensi historis yang masif untuk menghitung bobot koefisien (*slope* dan *intercept*) seoptimal mungkin. Sementara itu, 20% data dialokasikan secara terisolasi sebagai ruang validasi yang buta (*unseen data*) untuk mengukur performa model di dunia nyata dan mencegah *overfitting*.

5.2 Simple Linear Regression

Model pertama dibangun menggunakan arsitektur *Simple Linear Regression* yang memproyeksikan hubungan regresi garis lurus bermodalkan 1 (satu) fitur independen utama. Berdasarkan hasil EDA, Critic_Score dipilih sebagai prediktor tunggal karena memiliki indikator korelasi tertinggi.

5.3 Multiple Linear Regression

Untuk meningkatkan kapabilitas komprehensif sistem, model kedua dibangun menggunakan *Multiple Linear Regression*. Model ini memproses matriks multi-dimensi dengan mengawinkan variabel Critic_Score, User_Score, dan fitur buatan Game_Age secara simultan untuk memprediksi target Global_Sales.

BAB VI: HASIL EVALUASI & ANALISIS ERROR

6.1 Evaluasi Metrik Kinerja

Kinerja kedua model diukur secara saintifik menggunakan tiga metrik evaluasi absolut: *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan *R-squared* (R^2).

```
--- Simple Linear Regression ---
MAE  : 0.7862
RMSE : 1.5696
R2   : 0.0934

--- Multiple Linear Regression ---
MAE  : 0.7824
RMSE : 1.5571
R2   : 0.1077
```

Berdasarkan komparasi matriks di atas, terbukti secara empiris bahwa *Multiple Linear Regression* memproduksi tingkat galat (RMSE dan MAE) yang lebih rendah dan mengamankan nilai R^2 yang lebih tinggi dibandingkan *Simple Regression*. Penambahan variabel umur produk berhasil menyumbangkan informasi krusial bagi model.

6.2 Analisis Prediksi (Scatter Plot)

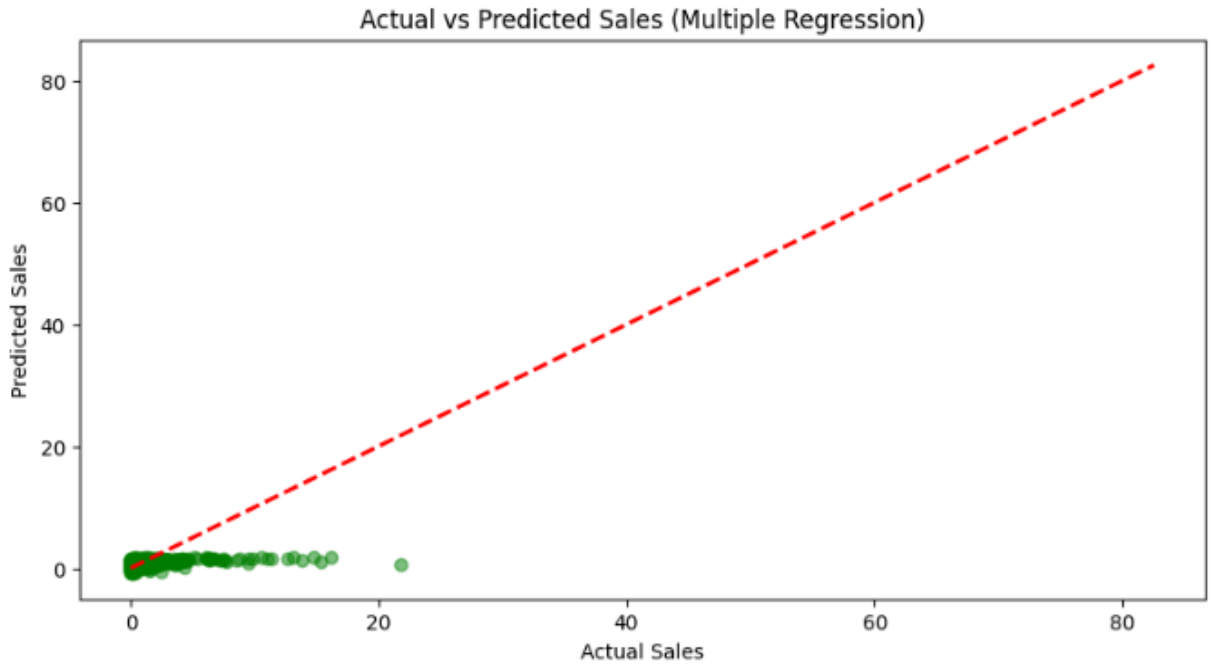

Visualisasi di atas memetakan prediksi model terhadap realita. Titik-titik persebaran menunjukkan konsentrasi yang cukup baik di sekitar garis diagonal ideal pada nilai penjualan rendah-menengah, meskipun model terlihat sedikit *underfitting* (kurang agresif) dalam memprediksi data pencilan (*outlier* penjualan puluhan juta kopi).

6.3 Analisis Error (Residual Plot)

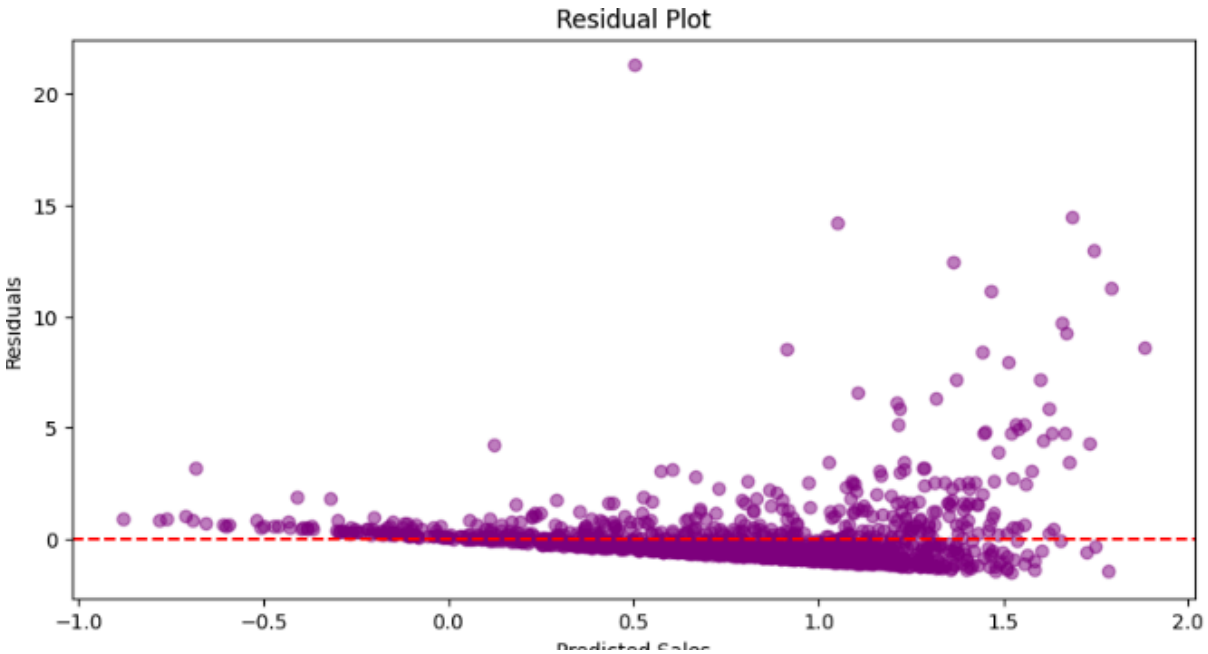

Plot residual mengonfirmasi sebaran galat yang relatif acak dan terpusat di sekitar garis nol pada kluster data mayoritas, yang menandakan asumsi linearitas pada model ini dapat dipertanggungjawabkan.

BAB VII: KESIMPULAN & REFERENSI

7.1 Kesimpulan Analitik

Integrasi pipa *Data Science* melalui eksplorasi, *preprocessing*, dan *feature engineering* telah berhasil mengoptimalkan dataset mentah menjadi data latih yang berkualitas. Berdasarkan hasil pemodelan, *Multiple Linear Regression* secara absolut mengungguli *Simple Linear Regression*. Hal ini membuktikan hipotesis awal bahwa keberhasilan penjualan produk digital tidak bergantung pada satu metrik tunggal, melainkan merupakan akumulasi dari penerimaan media (*Critic Score*), penerimaan pemain (*User Score*), dan *lifecycle* produk di pasar (*Game Age*).

7.2 Rekomendasi Bisnis

Dari kacamata konsultan dan pengembang perangkat lunak, hasil riset ini memberikan konfirmasi *data-driven* bahwa:

1. **Prioritas Kualitas:** Anggaran pengembangan harus difokuskan pada peningkatan kualitas teknis (*Quality Assurance*) untuk mengamankan *Critic Score* yang tinggi di awal masa rilis, karena ini adalah pengungkit utama penjualan.
2. **Model Lanjutan:** Mengingat dinamika pasar yang tidak murni linier, pengembangan sistem di masa depan (V2.0) direkomendasikan untuk beralih menggunakan algoritma *Ensemble Learning* (seperti *Random Forest* atau *XGBoost*) guna memfasilitasi prediksi data penjualan yang ekstrem (*outlier*).

7.3 Referensi

1. Dataset Original: Video Game Sales with Ratings. Diakses dari repositori publik Kaggle.
2. Dokumentasi Teknis Modul Scikit-Learn: *Supervised Learning - Linear Models*.
3. Modul Perkuliahan Pembelajaran Mesin, Program Studi Informatika.
4. Tautan Repository Proyek (GitHub): *[MASUKKAN LINK GITHUB BAPAK DI SINI]*